

# 從零開始的 關聯式學習

Pandas 與 Mlxtend

張家瑋 博士

副教授

國立臺中科技大學資訊工程系



A.I.  
Big Data  
Images  
Videos  
IoT  
Audios  
Texts



## Work Experience

- 2022/2~ Now  
**Associate Professor**  
National Taichung University of Science and Technology
- 2018/2 ~ Now  
**Adjunct Assistant Professor**  
National Cheng Kung University
- 2015/8 ~ 2017/11  
**Project Manager & Data Scientist**  
NEXCOM International Co., Ltd.

## About Me

- [Since Jan. 2019] Young Professionals Chair, IET Taipei Local Network.
- [Since Dec. 2017] Consultant, NEXCOM Industry 4.0 Center.
- [Jan. 2017] Ph.D. degree, National Cheng Kung University.

## Research Topics

- a) Natural Language Processing
  - ✓ Natural Language Understanding
  - ✓ Chatbot
  - ✓ Text Summarization / Classification
- b) Deep Learning
- c) Data Mining
- d) Internet of Things
  - ✓ Smart Speaker



# Basic Background of Data Science



# Data?

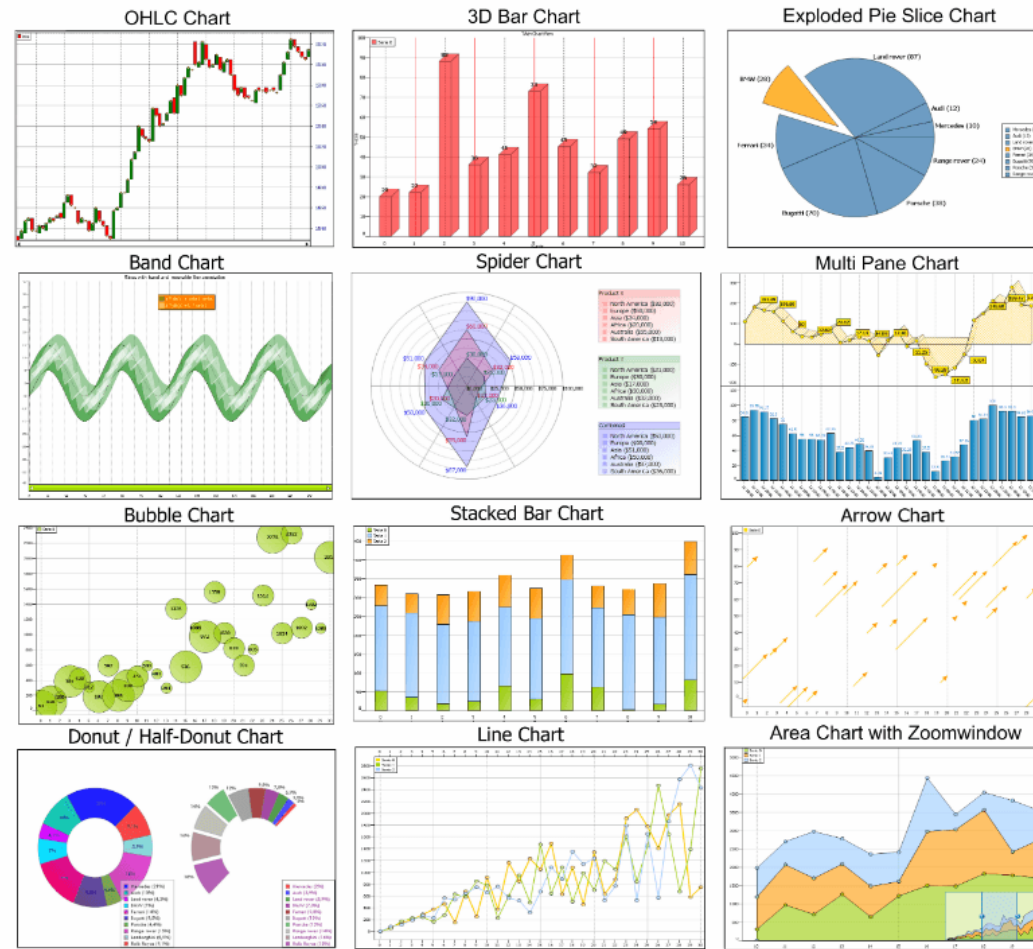
[illegible]

- 未經過處理的原始記錄。
- 資料**缺乏組織及分類**，無法明確的表達事物代表的意義。
- 資料是關於事件的一組**離散且客觀**的事實描述，是構成資訊和知識的原始材料。

# Information?

- 資訊是經過處理後的資料。
- 資訊是有用的或有意義的資料。
- 對接受者**有意義的資料能使接受者產生資訊**。

# Information?



# Knowledge?

- 知識是資訊、文化脈絡以及經驗的**整合**。
- 知識是對**某個主題**確信的認識，並且這些認識擁有潛在的能力為**特定目的**而使用。
- 藉由**專業技能**或**豐富經驗**用以分析資訊的結果。

# Intelligence?

- 以知識為基礎，**運用**個人能力，  
**實踐**能力來開創價值。
- 分析、判斷、創造、思考的能力。
- 智慧具有反應能力與價值判斷。



# 人工智慧？

- 指由人製造出來的機器所表現出來的智慧。(Wiki)
- 弱人工智慧 → 專家系統
  - 處理特定的問題
- 強人工智慧
  - 通用人工智慧

# 過去

- Small Data

- 針對某一個問題，只能獲得少量數據。
- 數百筆到數萬筆。
- 花費大量人工編碼。

# 過去

- Small Data 統計分析
  - 樣本推論母體(抽樣)
  - 在小樣本中，需要發展一系列理論來解釋事物的原理(學說)
  - [啟示] 1936 羅斯福與藍頓 的民調

# 過去

- 小數據
- Rule-based AI
- 類神經網路 (1980s)

# 現在與未來

- Big Data
  - 由"母體"來分析數據
  - 數萬筆到幾近無限
  - 雜亂的原始資料



# 上一世代

- 大數據
- 分類：SVM → 機器學習
- 分群：Kmeans
- 關聯式法則：Apriori

# What's difference?

- Small Data vs Big Data
  - 都有目的或待解的問題

But

- 減少假設
- 力求呈現真實世界

# What's difference?

- 資料可重組與檢視關聯。
- 接受「數據的雜亂性」，不再追求「精確」的數據。
- 重「相關」而輕「因果」。

# 現在

- 大數據
- 運算力的提升
- 深度學習 (強AI的可能性)
  - 類神經網路的文藝復興
- 演進趨勢
  - 腦神經科學
  - 認知科學
  - 認知心理學

# Big Data 的沿革 (1/3)

- Data Mining
  - 資料探勘是利用分析技術來發掘資料間**未知的關聯性與規則**。
  - 少女未婚懷孕 購物商場比老爸還早知道？！
    - <https://www.nownews.com/news/20120223/42676>



# Data Mining

- ✓ 分群

- 用於沒有標籤的資料，又通常為非監督式演算法。

- ✓ 分類

- 用於有標籤的資料，又通常為監督式演算法。

- ✓ 關聯式法則

- 有序性規則的資料

# Data Mining

## ✓ 分群


- 一 用於沒有標籤的資料，又通常為非監督式演算法。

RespondentId	StartDate	CompletedDate	LanguageCode	Question1	Question2	Question3	Question4	Question5	Question6	Question7	Question8
27357	2006.11.27	2006.11.27	en	Denmark, Financial Services, 6 - 12 months, 26-100, 4, 4, 2, "cvbcbv", 2, 3, 3, 1, 0, 0, 1							
27359	2006.11.27	2006.11.27	en	Italy, Hardware Vendor, 1 - 2 years, 26-100, 3, 5, 4, 1, 3, 3, 4, 0, 0, 0, 1, 0, 0, 0							
27360	2006.11.27	2006.11.27	en	Lithuania, Retail, 6 - 12 months, 6-10, 4, 1, 4, "this is a random other text", 2, 2, 2, 2, 0, 0, 1							
27361	2006.11.27	2006.11.27	en	Panama, Retail, 6 - 12 months, 6-10, 4, 1, 4, "this is a random other text", 2, 2, 2, 2, 0, 0, 1							
27362	2006.11.27	2006.11.27	en	Djibouti, Manufacturing, 6+ years, 101-250, 0, 4, 0, "another random text", 5, 5, 5, 5, 0, 0, 1							
27363	2006.11.27	2006.11.27	en	Tanzania, Retail, 1 - 2 years, 1001-5000, 1, 1, 1, "123456", 2, 2, 2, 2, 0, 0, 1, 1, 1, 1, 1, 1							
27364	2006.11.27	2006.11.27	en	Vanuatu, Other, 1 - 2 years, 1001-5000, 6, 5, 6, "123456", 6, 6, 6, 6, 0, 0, 1, 1, 1, 1, 0, 1, 1							
27365	2006.11.27	2006.11.27	en	Angola, Government, 1 - 2 years, 11-25, 4, 2, 4, "123456", 3, 3, 3, 3, 0, 0, 1, 1, 1, 1, 1, 0, 0							
27366	2006.11.27	2006.11.27	en	Panama, Manufacturing, <6 months, 1-5, 1, 4, 1, "hey", 5, 5, 5, 5, 0, 0, 1, 0, 0, 0, 1, 0, 0, "hey							
27367	2006.11.27	2006.11.27	en	Norway, Education, 2 - 5 years, 5001-10000, 6, 0, 6, "f6{[]]+&#x2013;*/+\\", 1, 1, 1, 1, 0, 0, 1, 0, 1							
27368	2006.11.27	2006.11.27	en	Bermuda, Software Vendor, 1 - 2 years, 11-25, 0, 2, 0, "123456", 3, 3, 3, 3, 0, 0, 1, 0, 1, 0, 0, 1, 0							
27369	2006.11.27	2006.11.27	en	Maldives, Transportation, 1 - 2 years, 11-25, 5, 4, 5, "123456", 5, 5, 5, 5, 0, 0, 1, 0, 0, 0, 1, 0, 0							
27370	2006.11.27	2006.11.27	en	Maldives, Other, 6+ years, 10001 or more, 2, 5, 2, "another random text", 6, 6, 6, 6, Network Pro							
27371	2006.11.27	2006.11.27	en	Kyrgyzstan, Medical, 2 - 5 years, 26-100, 3, 5, 3, "f6{[]]+&#x2013;*/+\\", 6, 6, 6, 6, Network Pro							
27372	2006.11.27	2006.11.27	en	Antigua and Barbuda, Government, 6 - 12 months, 501-1000, 6, 2, 6, "this is a random other t							
27373	2006.11.27	2006.11.27	en	Belarus, Financial Services, 6+ years, 10001 or more, 2, 1, 2, "another random text", 2, 2, 2, 2							
27374	2006.11.27	2006.11.27	en	Vatican City, Non-profit, 1 - 2 years, 11-25, 0, 0, 0, "123456", 1, 1, 1, 1, Network Probe, 1, 0, 0							
27375	2006.11.27	2006.11.27	en	Georgia, Financial Services, 6+ years, 10001 or more, 6, 1, 6, "another random text", 2, 2, 2, 2							
27376	2006.11.27	2006.11.27	en	Tokelau, Transportation, 1 - 2 years, 11-25, 2, 4, 2, "123456", 5, 5, 5, 5, Network Probe, 0, 1, 0, 0							
27377	2006.11.27	2006.11.27	en	Chad, Software Vendor, <6 months, 1-5, 6, 2, 6, "hey", 3, 3, 3, 3, Network Probe, 1, 1, 1, 1, 1, 1, 1							
27378	2006.11.27	2006.11.27	en	Turkey, Software Vendor, 6 - 12 months, 501-1000, 1, 2, 1, "this is a random other text", 3, 3							
27379	2006.11.27	2006.11.27	en	East Timor, Transportation, <6 months, 1-5, 0, 4, 0, "hey", 5, 5, 5, 5, 0, 0, 1, 1, 0, 0, 1, 0, 1, 0							
27380	2006.11.27	2006.11.27	en	Nicaragua, Medical, 6 - 12 months, 6-10, 5, 5, 5, "this is a random other text", 6, 6, 6, 6, Opin							
27381	2006.11.27	2006.11.27	en	Equatorial Guinea, Software Vendor, 6+ years, 101-250, 6, 2, 6, "another random text", 3, 3, 3							
27382	2006.11.27	2006.11.27	en	Zambia, Retail, <6 months, 251-500, 1, 1, 1, "hey", 2, 2, 2, 2, Surveyor, 0, 1, 0, 0, 0, 0, 1, 0, "hey							
27383	2006.11.27	2006.11.27	en	French Southern and Antarctic Lands, Retail, 1 - 2 years, 1001-5000, 2, 1, 2, "123456", 2, 2, 2							
27384	2006.11.27	2006.11.27	en	Guinea-Bissau, Hardware Vendor, 2 - 5 years, 26-100, 6, 3, 6, "f6{[]]+&#x2013;*/+\\", 4, 4, 4, 4							
27385	2006.11.27	2006.11.27	en	Viet Nam, Medical, 2 - 5 years, 26-100, 4, 5, 4, "f6{[]]+&#x2013;*/+\\", 6, 6, 6, 6, 0, 0, 1, 1, 1							
27386	2006.11.27	2006.11.27	en	Reunion, Medical, 1 - 2 years, 1001-5000, 2, 5, 2, "123456", 6, 6, 6, 6, 0, 0, 1, 1, 1, 1, 1, 1, 1							
27387	2006.11.27	2006.11.27	en	Puerto Rico, Non-profit, <6 months, 1-5, 0, 0, 0, "hey", 1, 1, 1, 1, 0, 0, 1, 1, 1, 0, 1, 1, 0, 1, "h							
27388	2006.11.27	2006.11.27	en	East Timor, Financial Services, 6 - 12 months, 6-10, 1, 1, 1, "this is a random other text",							
27389	2006.11.27	2006.11.27	en	Northern Mariana Islands, Software Vendor, <6 months, 1-5, 2, 2, 2, "hey", 3, 3, 3, 3, 0, 0, 1, 0							

# Data Mining

## ✓ 分群

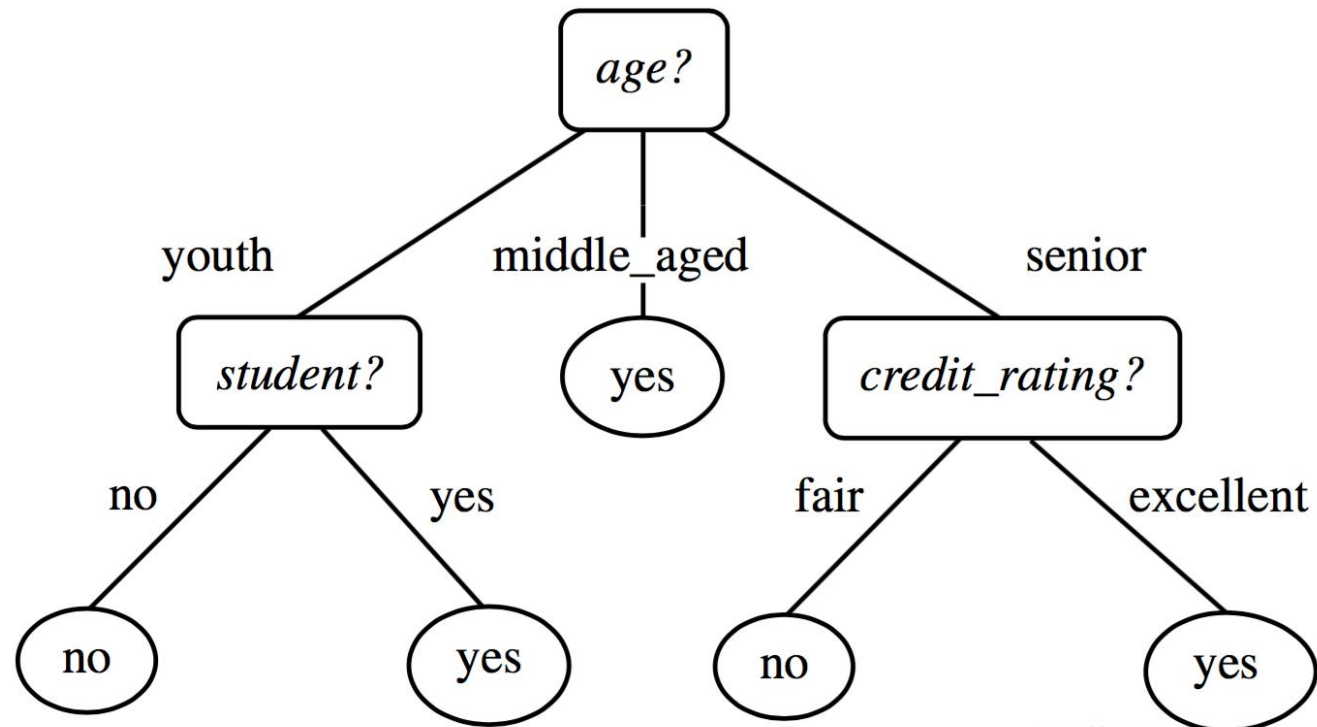
- 用於沒有標籤的資料，又通常為非監督式演算法。



# Data Mining

## ✓ 分類

- 用於有標籤的資料，又通常為監督式演算法。

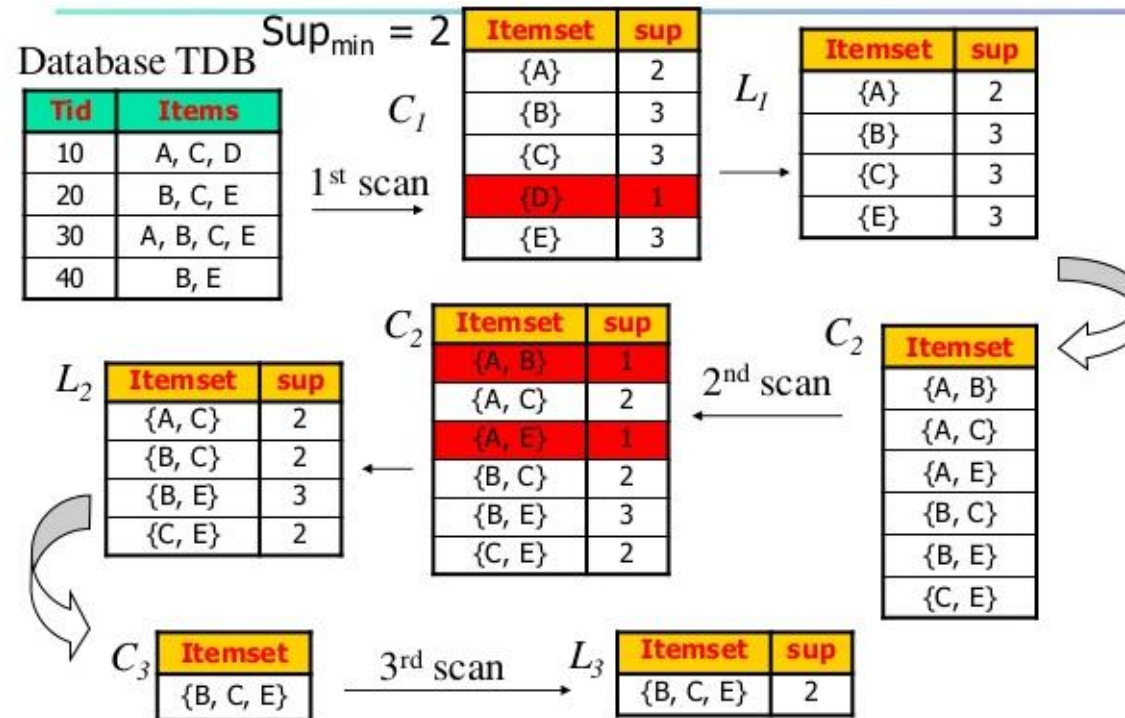


<http://blog.csdn.net/guoziqing506>

# Data Mining

## ✓ 關聯式法則

### – 有序性 (尿布與啤酒)






# Big Data 的沿革 (2/3)

- Machine Learning
  - 人工智慧的分支，可用於資料探勘。
  - 讓機器可以自動學習、從巨量資料中找到規則，  
進而有能力做出分類或預測。
    - 判斷出類別
    - 估計出數值

# Big Data 的沿革 (3/3)

- Deep Learning

- 是機器學習的分支
- 類神經網路的文藝復興
- 從大規模未標記資料中建立更好的預測模型
- 建立強 AI 的可能性



# 資料分析的基本步驟

1. 資料清除：去除極端、遺失值資料、不重要的屬性
2. 資料整合：因應用目的或特性，整合不同來源的資料
3. 資料選擇：揀選重要的屬性來逼近目的之最佳成效
4. 資料轉換：基於領域知識進行特徵縮放、數值類別轉換等
5. 資料探勘：選用合適的分析演算法得到目的之結果
6. 樣式評估：評估結果的樣式，是否如預期
7. 知識表示：因應目的將樣式轉換成合適的表達方法

# 資料分析的演算法重點

- 預處理 ( Preprocessing )
- 降維 ( Dimensionality Reduction )
- 模型選擇 ( Model Selection )
  - 監督式學習 ( Supervised learning )
    - 分類 ( Classification ) : 機器給出一個類別
    - 迴歸 ( Regression ) : 機器給出一個數值
  - 非監督式學習 ( Unsupervised learning )
    - 分群 ( Clustering )
  - 關聯式學習 ( Association Rule Learning )

# 資料分析的常見角色

- 資料產品經理人：將真實世界的問題轉換成資料可以解決的問題，通常是該問題領域的專業人士
- 資料工程師：蒐集、整理、清理資料，通常是具備程式技術能力的工程師
- 資料分析師：負責資料建模和分析，通常由擅長找出資料關聯的統計人擔當
- 資料視覺化設計師：將報表變得簡明易懂



# 資料驅動創新應用

- 文字、聲音、影像
  - 自然語言處理
  - 語音辨識
  - 影像辨識
- 數值與非數值
  - 連續性
  - 離散性、類別



Open Datasets

# UC Irvine Machine Learning Repository

<http://archive.ics.uci.edu/ml/datasets.html>



**Machine Learning Repository**  
Center for Machine Learning and Intelligent Systems

[About](#) [Citation Policy](#) [Donate a Data Set](#) [Contact](#)

Search

任務

資料型態

資料筆數

Browse Through: 426 Data Sets







Default Task	Name	Data Types	Default Task	Attribute Types	# Instances	# Attributes	Year
<b>Classification (314)</b> Regression (82) Clustering (72) Other (54)	 Abalone	Multivariate	Classification	Categorical, Integer, Real	4177	8	1995
<b>Attribute Type</b> Categorical (37) Numerical (273) Mixed (55)	 Adult	Multivariate	Classification	Categorical, Integer	48842	14	1996
<b>Data Type</b> Multivariate (324) Univariate (19) Sequential (44) Time-Series (79) Text (44) Domain-Theory (23) Other (21)	 Annealing	Multivariate	Classification	Categorical, Integer, Real	798	38	
<b>Area</b> Life Sciences (98) Physical Sciences (47) CS / Engineering (148) Social Sciences (24) Business (26) Game (10) Other (69)	 Anonymous Microsoft Web Data		Recommender-Systems	Categorical	37711	294	1998
<b># Attributes</b> Less than 10 (99) 10 to 100 (195) Greater than 100 (76)	 Arrhythmia	Multivariate	Classification	Categorical, Integer, Real	452	279	1998
<b># Instances</b> Less than 100 (25) 100 to 1000 (149) Greater than 1000 (220)	 Artificial Characters	Multivariate	Classification	Categorical, Integer, Real	6000	7	1992
<b>Format Type</b> Matrix (292) Non-Matrix (134)	 Audiology (Original)	Multivariate	Classification	Categorical	226		1987
	 Audiology (Standardized)	Multivariate	Classification	Categorical	226	69	1992
	 Auto MPG	Multivariate	Regression	Categorical, Real	398	8	1993
	 Automobile	Multivariate	Regression	Categorical, Integer, Real	205	26	1987
	 Badges	Univariate, Text	Classification		294	1	1994

# Kaggle DataSets

<https://www.kaggle.com/datasets>

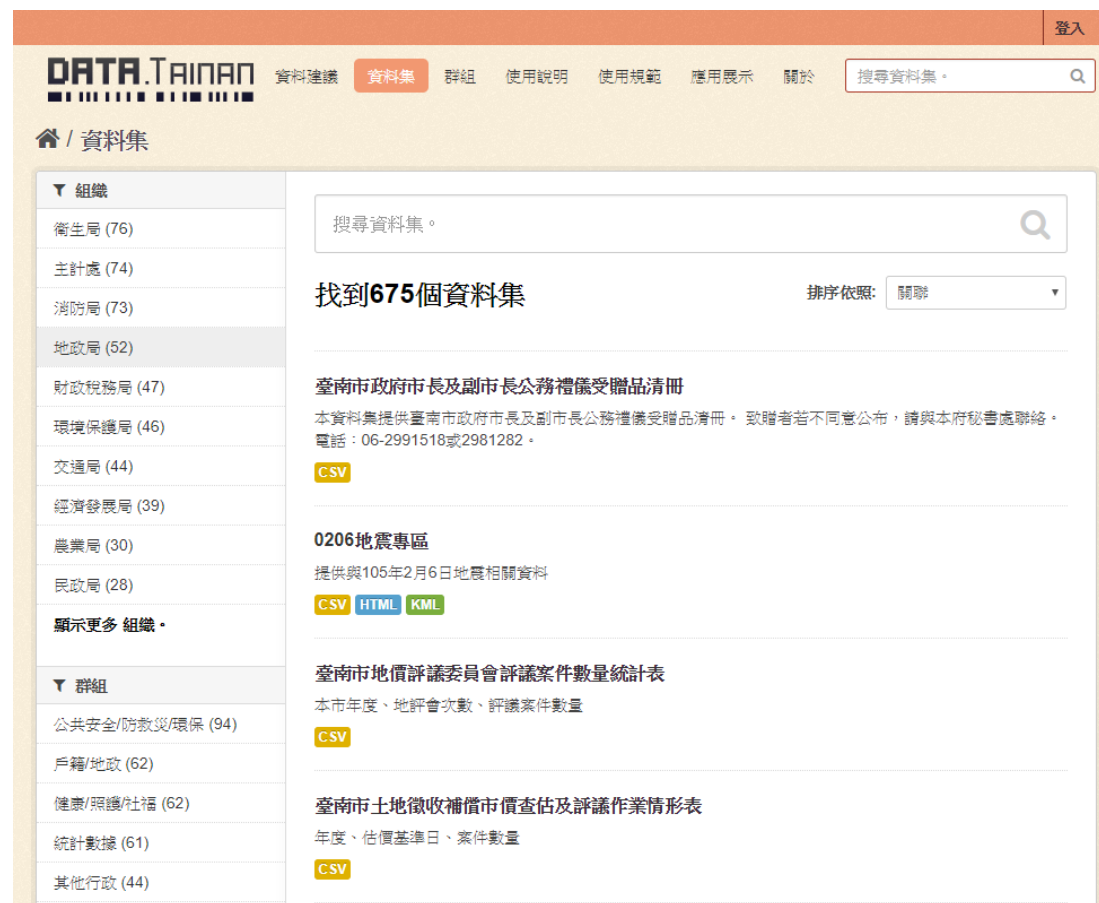
Public Sort by Hotness

12,800 Datasets Sizes File types Licenses Tags Search datasets

373		<b>Data Science for Good: Kiva Crowdfunding</b> Use Kernels to assess welfare of Kiva borrowers for \$30k in prizes Kiva updated 10 days ago	geography finance lending + 2 more...	CSV 42 MB CC0	<> 106 27 45k
295		<b>Trending YouTube Video Statistics</b> Daily statistics for trending YouTube videos Mitchell J updated 12 hours ago	languages popular culture statistics + 2 more...	CSV 64 MB CC0	<> 27 10 51k
254		<b>Huge Stock Market Dataset</b> Historical daily prices and volumes of all U.S. stocks and ETFs Boris Marjanovic updated 4 months ago	business finance economics artificial intelligen...	Other 245 MB CC0	<> 12 7 28k
154		<b>Bitcoin Blockchain</b> Complete live historical Bitcoin blockchain data Google BigQuery updated a month ago	finance money internet bigquery	BigQuery 821 GB CC0	<> 430 6 31k
70		<b>Historical Air Quality</b> Air Quality Data Collected at Outdoor Monitors Across the US US Environmental Protection Agency updated 3 months ago	pollution bigquery	BigQuery 323 GB CC0	<> 16 1 17k
63		<b>HackerRank Developer Survey 2018</b> Survey of 25,000 professionals and students on the state of developer skills HackerRank updated 12 days ago	women demographics programming + 2 more...	CSV 5 MB CC4	<> 17 1 6k

# 臺南市開放資料

<http://data.tainan.gov.tw/dataset>



The screenshot shows the Tainan Open Data website interface. At the top, there is a navigation bar with the 'DATA.TAINAN' logo and links for '資料建議', '資料集', '群組', '使用說明', '使用規範', '應用展示', and '關於'. A search bar is located on the right side of the navigation bar. Below the navigation bar, the main content area is titled '資料集'. On the left side, there is a sidebar with a list of organizations and groups. The main content area displays a search bar, a result count of '找到675個資料集', and a list of datasets. The first dataset is '臺南市政府市長及副市長公務禮儀受贈品清冊', which is a CSV file. The second dataset is '0206地震專區', which is a CSV file. The third dataset is '臺南市地價評議委員會評議案件數量統計表', which is a CSV file. The fourth dataset is '臺南市土地徵收補償市價查估及評議作業情形表', which is a CSV file.

登入

DATA.TAINAN

資料建議 資料集 群組 使用說明 使用規範 應用展示 關於

搜尋資料集。

搜尋資料集。

找到675個資料集

排序依照: 關聯

臺南市政府市長及副市長公務禮儀受贈品清冊

本資料集提供臺南市政府市長及副市長公務禮儀受贈品清冊。致贈者若不同意公布，請與本府秘書處聯絡。電話：06-2991518或2981282。

CSV

0206地震專區

提供與105年2月6日地震相關資料

CSV HTML KML

臺南市地價評議委員會評議案件數量統計表

本市年度、地評會次數、評議案件數量

CSV

臺南市土地徵收補償市價查估及評議作業情形表

年度、估價基準日、案件數量

CSV

組織

- 衛生局 (76)
- 主計處 (74)
- 消防局 (73)
- 地政局 (52)
- 財政稅務局 (47)
- 環境保護局 (46)
- 交通局 (44)
- 經濟發展局 (39)
- 農業局 (30)
- 民政局 (28)
- 顯示更多 組織

群組

- 公共安全/防救災/環保 (94)
- 戶籍/地政 (62)
- 健康/照護/社福 (62)
- 統計數據 (61)
- 其他行政 (44)



# 關聯規則學習

## Association Rule Learning

# 概念

- 在大型資料庫中發現項目間關聯的方法。
  - {牛奶, 麵包}→{可樂}：代表某人同時買了牛奶和麵包，就可能會買可樂。
- 該方法常使用於電子商務上，通常可為**促銷**、**產品推薦**等行銷活動的決策依據。



# 定義

- 商品的項目集合(itemset) ,  $I = \{ I_1, I_2, \dots, I_m \}$  ◦ #Item
- 交易資料庫(Database) ,  $D = \{ t_1, t_2, \dots, t_n \}$  ◦ #Transaction
- 關聯規則(Association Rule) ,  $X \rightarrow Y$




Apriori

# 概念

- 逐層搜索的迭代方法。
- $k$ -itemset 用於探索  $(k + 1)$  - itemset。
  1. 找出 frequent 1-itemset,  $F_1$ 。  $F_1$  用來找 frequent 2-itemset,  $F_2$ 。  
而  $F_2$  用來找到  $F_3$ 。直到不能找到  $k$ -itemset。
  2. 每找一個  $F_k$  需要掃描一次資料庫。為提高頻繁項集逐層產生的效率，  
Apriori 性質則可減少搜索。
- Apriori 性質：frequent itemset 的所有非空子集都必須是頻繁的。
  - 若某個  $k$ -itemset 的 candidate 的 subsets 不在  $(k-1)$ -itemset 時，  
這個 candidate 就可以直接刪除。

# 當最小支持度為 2 時的情況



# 方法

## 1. $C_3 = F_2$ 的組合

- $F_2 = \{\{A, C\}, \{B, C\}, \{B, E\}, \{C, E\}\}$

$$C_3 = \{\{A, B, C\}, \{A, C, E\}, \{B, C, E\}\}$$


## 2. 使用 Apriori 性質剪枝：某個 frequent itemset 的所有 subsets 必須是頻繁的，對 candidate itemset $C_3$ ，我們可以刪除其非頻繁的 subsets：

- $\{A, B, C\}$  的 2-itemset 是  $\{A, B\}, \{A, C\}, \{B, C\}$ ，其中  $\{A, B\}$  不是  $F_2$  的元素，所以刪除;
- $\{A, C, E\}$  的 2-itemset 是  $\{A, C\}, \{A, E\}, \{C, E\}$ ，其中  $\{A, E\}$  不是  $F_2$  的元素，所以刪除;
- $\{B, C, E\}$  的 2-itemset 是  $\{B, C\}, \{B, E\}, \{C, E\}$ ，所有 2-itemset 都是  $F_2$  的元素，因此保留。

## 3. 剪枝後得到 $C_3 = \{\{B, C, E\}\}$

# 剪枝

if {A,B} is infrequent



# 案例

TID	網球拍	網 球	運動鞋	羽毛球
1	1	1	1	0
2	1	1	0	0
3	1	0	0	0
4	1	0	1	0
5	0	1	1	1
6	1	1	0	0

- 顧客購買記錄的資料庫  $D$ ，包含 6 個 Transactions
- 項目集  $I = \{\text{網球拍}, \text{網球}, \text{運動鞋}, \text{羽毛球}\}$

觀察關聯規則，網球拍  $\rightarrow$  網球。

- Transaction 1, 2, 3, 4, 6 包含網球拍。
- Transaction 1, 2, 6 同時包含網球拍和網球。
- 支持度  $= 3/6 = 0.5$ ，信心度  $= 3/5 = 0.6$ 。

- 若最小支持度為 0.5，最小信心度為 0.6。
- 關聯規則 “網球拍  $\rightarrow$  網球” 是存在強關聯的。

- 1-itemset (4):  $\{\text{網球拍}\}, \{\text{網球}\}, \{\text{運動鞋}\}, \{\text{羽毛球}\}$
- 2-itemset (7):  $\{\text{網球拍}, \text{網球}\}, \{\text{網球拍}, \text{運動鞋}\}, \{\text{網球拍}, \text{羽毛球}\},$   
 $\{\text{網球}, \text{運動鞋}\}, \{\text{網球}, \text{羽毛球}\}, \{\text{運動鞋}, \text{羽毛球}\}$
- 3-itemset (4):  $\{\text{網球拍}, \text{網球}, \text{運動鞋}\}, \{\text{網球拍}, \text{網球}, \text{羽毛球}\}, \{\text{網球拍}, \text{運動鞋}, \text{羽毛球}\}$   
 $\{\text{網球}, \text{運動鞋}, \text{羽毛球}\}$



實作開始



# Google Colab



<https://colab.research.google.com/>

# Mlxtend

[http://rasbt.github.io/mlxtend/api\\_subpackages/mlxtend.frequent\\_patterns/](http://rasbt.github.io/mlxtend/api_subpackages/mlxtend.frequent_patterns/)

**min\_support**: float (default: 0.5)

✓ A float between 0 and 1 for minimum support of the itemsets returned.

$\text{transactions\_where\_item(s)\_occur} / \text{total\_transactions}$

$\text{support}(A \rightarrow C) = \text{support}(A \cup C), \quad \text{range: } [0, 1]$

$\text{confidence}(A \rightarrow C) = \frac{\text{support}(A \rightarrow C)}{\text{support}(A)}, \quad \text{range: } [0, 1]$

# Mlxtend

[http://rasbt.github.io/mlxtend/user\\_guide/frequent\\_patterns/association\\_rules/](http://rasbt.github.io/mlxtend/user_guide/frequent_patterns/association_rules/)

$$\text{lift}(A \rightarrow C) = \frac{\text{confidence}(A \rightarrow C)}{\text{support}(C)}, \quad \text{range: } [0, \infty] \quad = \quad \frac{\text{Support}}{\text{Supp}(X) \times \text{Supp}(Y)}$$

$$\text{leverage}(A \rightarrow C) = \text{support}(A \rightarrow C) - \text{support}(A) \times \text{support}(C), \quad \text{range: } [-1, 1]$$

$$\text{conviction}(A \rightarrow C) = \frac{1 - \text{support}(C)}{1 - \text{confidence}(A \rightarrow C)}, \quad \text{range: } [0, \infty] \quad = \quad \frac{P(A)P(B')}{P(A \cap B')}$$

# UCI - Online Retail Data Set



Machine Learning Repository

Center for Machine Learning and Intelligent Systems

<https://archive.ics.uci.edu/ml/datasets/online+retail>

Check out the [beta version](#) of the new UCI Machine Learning Repository we are currently testing! [Contact us](#) if you have any issues, questions, or concerns. [Click here to try out the new site.](#)

## Online Retail Data Set

Download: [Data Folder](#), [Data Set Description](#)

**Abstract:** This is a transnational data set which contains all the transactions occurring between 01/12/2010 and 09/12/2011 for a UK-based and registered non-store online retail.

Data Set Characteristics:	Multivariate, Sequential, Time-Series	Number of Instances:	541909	Area:	Business
Attribute Characteristics:	Integer, Real	Number of Attributes:	8	Date Donated	2015-11-06
Associated Tasks:	Classification, Clustering	Missing Values?	N/A	Number of Web Hits:	764798

### Source:

Dr Daqing Chen, Director: Public Analytics group. [chend '@' lsbu.ac.uk](mailto:chend '@' lsbu.ac.uk), School of Engineering, London South Bank University, London SE1 0AA, UK.

### Data Set Information:

This is a transnational data set which contains all the transactions occurring between 01/12/2010 and 09/12/2011 for a UK-based and registered non-store online retail. The company mainly sells unique all-occasion gifts. Many customers of the company are wholesalers.

### Attribute Information:

InvoiceNo: Invoice number. Nominal, a 6-digit integral number uniquely assigned to each transaction. If this code starts with letter 'c', it indicates a cancellation.  
StockCode: Product (item) code. Nominal, a 5-digit integral number uniquely assigned to each distinct product.  
Description: Product (item) name. Nominal.  
Quantity: The quantities of each product (item) per transaction. Numeric.  
InvoiceDate: Invoice Date and time. Numeric, the day and time when each transaction was generated.  
UnitPrice: Unit price. Numeric, Product price per unit in sterling.  
CustomerID: Customer number. Nominal, a 5-digit integral number uniquely assigned to each customer.  
Country: Country name. Nominal, the name of the country where each customer resides.



懶人包  
[ [link](#) ]



Thank you